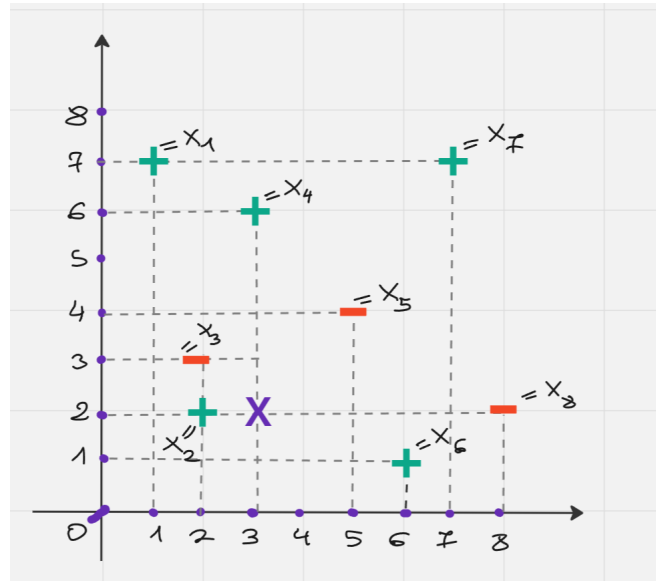


## Algorytm KNN.

### Klasyfikacja nowego obiektu.

Na płaszczyźnie wśród punktów o znanych wartościach "+" i "-" pojawił się nowy punkt, jak na rysunku poniżej.



Zadanie polega na przypisaniu nowego punktu  $X$  wartości "+" lub "-" w oparciu o modę (dominantę) wartości sąsiadujących z nim punktów. W tym celu:

1. Obliczamy odległości wszystkich punktów  $X_i$  od punktu  $X$ .

$$X_1 = (1, 7) \Rightarrow d_1 = d(X_1, X) = ((1, 7), (3, 2)) = \sqrt{2^2 + 5^2} = \sqrt{29},$$

$$X_2 = (2, 2) \Rightarrow d_2 = d(X_2, X) = 1 = \sqrt{1},$$

$$X_3 = (2, 3) \Rightarrow d_3 = d(X_3, X) = \sqrt{2},$$

$$X_4 = (3, 6) \Rightarrow d_4 = 4 = \sqrt{16},$$

$$X_5 = (5, 4) \Rightarrow d_5 = \sqrt{8},$$

$$X_6 = (6, 1) \Rightarrow d_6 = \sqrt{10},$$

$$X_7 = (7, 7) \Rightarrow d_7 = \sqrt{41},$$

$$X_8 = (8, 2) \Rightarrow d_8 = 5 = \sqrt{25}.$$

2. Porządkujemy odległości rosnąco

Ponieważ

$$1 < \sqrt{2} < \sqrt{8} < \sqrt{10} < \sqrt{16} < \sqrt{25} < \sqrt{29} < \sqrt{36},$$

to

$$d_2 < d_3 < d_5 < d_6 < d_4 < d_8 < d_1 < d_7.$$

Możemy więc stworzyć wektor

$$D = [d_2, d_3, d_5, d_6, d_4, d_8, d_1, d_7]$$

uporządkowanych odległości.

3. Ustalamy  $k$  i klasyfikujemy nowy punkt w oparciu o  $k$  najbliższych mu sąsiadów. Jeśli:

- $k = 1$ , to wybieramy pierwszego najbliższego sąsiada - jest on oddalony od  $X$  o 1. Innymi słowy, wybieramy pierwszy element wektora  $D$ . Ten element to  $d_2$ . Oznacza to, że najbliższym sąsiadem jest  $X_2$ , którego etykieta  $y_2$  to "+", zatem w tym przypadku etykieta nowego punktu to "+". Sytuację tę można przedstawić schematycznie następująco:

$$k = 1 \rightarrow D[0] = d_2 \mapsto X_2 \mapsto y_2 = "+" \Rightarrow y = y_2 = "+".$$

- $k = 2$ , to wybieramy dwóch najbliższych sąsiadów. Oznacza to, że interesują nas 2 pierwsze elementy wektora  $D$ . Zatem

$$k = 2 \rightarrow D[0, 1] = [d_2, d_3] \mapsto [X_2, X_3] \mapsto [y_2, y_3] = [" + ", " - "].$$

Jak widać, jest to sytuacja nierozstrzygająca, możemy wtedy np. zwiększyć liczbę sąsiadów.

- $k = 3$ , co oznacza, że wybieramy 3 pierwsze elementy wektora  $D$ . Zatem:

$$k = 3 \rightarrow D[0, 1, 2] = [d_2, d_3, d_5] \mapsto [X_2, X_3, X_5] \mapsto [y_2, y_3, y_5].$$

A ponieważ

$$[y_2, y_3, y_5] = [" + ", " - ", " + "],$$


to

$$y = M_o(y_2, y_3, y_5) = " + ",$$

gdzie  $M_o$  oznacza dominantę danego zbioru.

### Zadanie regresji.

Regresja polega na przewidywaniu wartości ciągłej zmiennej zależnej w oparciu o znane wartości zmiennych niezależnych.



Zadanie polega na wyznaczeniu wartości dla nowego punktu  $X = 12,25$ . W tym celu:

1. Powtarzamy kroki 1 i 2, aby otrzymać uporządkowany wektor odległości

$$D = [d_3, d_4, d_2, d_1, d_5],$$

gdzie

$$d_3 = d(X, X_3) = 3,25,$$

$$d_4 = d(X, X_4) = 3,75,$$

$$d_2 = d(X, X_2) = 8,25,$$

$$d_1 = d(X, X_1) = 12,25,$$

$$d_5 = d(X, X_5) = 12,75.$$

2. Następnie wybieramy  $k$  i ustalamy wartość nowego punktu jako średnią arytmetyczną  $\mu$  z wartości  $k$  najbliższych sąsiadów.

- Dla  $k = 1$  wybieramy pierwszego najbliższego sąsiada. Ponieważ średnia arytmetyczna z jednej liczby jest równa tej liczbie to

$$k = 1 \rightarrow D[0] = d_3 \mapsto X_3 \mapsto y_3 = 3,25 \Rightarrow y = y_3 = 3,25.$$

- Dla  $k = 2$  obliczamy średnią arytmetyczną z dwóch najbliższych sąsiadów a zatem

$$k = 2 \rightarrow D[0, 1] = [d_3, d_4] \mapsto [X_3, X_4] \mapsto [y_3, y_4] = [3, 4] \Rightarrow y = \mu(y_3, y_4) = \frac{3+4}{2} = 3,5.$$

- Analogicznie dla  $k = 3$ ,  $y = \frac{y_3+y_4+y_2}{3} = \frac{3+4+2}{3} = 3$ , itd.